

2. תיאור המשימה

2.1. Hard & Soft Sum

① האם קיימת ממשלה:

$$\forall i \quad y_i x_i^T w + y_i b \geq 1 \quad = \quad \forall i \quad y_i (\langle w, x_i \rangle + b) \geq 1$$

$$\forall i \quad -y_i x_i^T w - y_i b \leq -1 \quad \text{נכתב למעשה הבעיה}$$

$$v_i \in \mathbb{R}^{d+1} \quad \text{אם } A \in \mathbb{M}_{n \times (d+1)} \quad \text{אז}$$

$$\forall i \quad -y_i x_i^T w - y_i b \leq -1 \iff \forall i \quad A v_i \leq d_i$$

$$\forall i \quad [A]_i = -\left[\frac{y_i x_i}{y_i}\right] \quad v_i = \begin{bmatrix} w \\ b \end{bmatrix} \quad d_i = -1$$

קיים פתרון:

$$A v \leq d \iff \forall i \quad A_i v_i \leq -1$$

$$\iff -y_i x_i^T w - y_i b \leq -1 \iff y_i x_i^T w + y_i b \geq 1 \iff y_i (\langle w, x_i \rangle + b) \geq 1$$

$$Q \in \mathbb{M}_{(d+1) \times (d+1)} \quad \alpha = 0 \quad \text{אם } \alpha > 0$$

$$Q_{ij} = \frac{1}{i+j-1}$$

$$\arg \min \|w\|^2 = \arg \min \begin{bmatrix} w \\ b \end{bmatrix}^T Q \begin{bmatrix} w \\ b \end{bmatrix}$$

$$= \arg \min \frac{1}{2} \begin{bmatrix} w \\ b \end{bmatrix}^T Q \begin{bmatrix} w \\ b \end{bmatrix} + \alpha^T \begin{bmatrix} w \\ b \end{bmatrix} = \arg \min \frac{1}{2} v^T Q v + \alpha^T v$$

(אם α הוא וקטור)

(אם α)

הערות:

② k איז א נומער, וואס איז גרעסער ווי 1. $\log k$ איז א נומער, וואס איז גרעסער ווי 1.

$$L(\theta | X, Y) = \prod_{i=1}^m f_{X,Y}(x_i, y_i | \theta) = \prod_{i=1}^m f_{X|Y=y_i}(x_i) \cdot f_{Y|\theta}(y_i)$$

$$= \prod_{i=1}^m \mathcal{N}(x_i | \mu_{y_i}, \sigma_{y_i}^2) \cdot \text{mult}(y_i | \pi)$$

יחסים x_j ו y נשמר ב (4)

דער, וואס טיילן ברענגט, נישט אלע ריפּוּק צו L זאל אַ ריפּוּק צו אַ מנחם אַלעס אַס בינער

דבר ראשון (1) ~ נספח:

$$l(\theta | x, y) = \log \left(\prod_{i=1}^n \mathcal{N}(x_i | \mu_{y_i}, \sigma_{y_i}^2) \cdot \text{mult}(y_i | \pi) \right)$$

$$= \sum_{i=1}^n \log(\text{mult}(y_i | \pi)) + \log(\mathcal{N}(x_i | \mu_{y_i}, \sigma^2_{y_i}))$$

$$= \sum_{i=1}^n \log(\pi y_i) + \log\left(\frac{1}{\sqrt{2\pi\sigma^2 y_i}} \exp\left(-\frac{(x_i - y_i)^2}{2\sigma^2 y_i}\right)\right)$$

$$= \sum_{i=1}^n \log(\pi y_i) - \frac{1}{2} \log(2\pi) - \frac{1}{2} \log(\sigma^2 y_i) - \frac{(x_i - \mu y_i)^2}{2\sigma^2 y_i}$$

$$= -\frac{n}{2} \log(2\pi) - \sum_k n_k \log(\pi_k) - \frac{1}{2} n_k \log(\sigma_k^2) - \frac{1}{2\sigma_k^2} \sum_{\{i|y_i=k\}} (x_i - \mu_k)^2$$

$$\bar{X}_k = \frac{1}{n_k} \sum_{i|y_i=k} X_i$$

$$n_k = \sum_i \mathbb{1}_{[y_i=k]} \quad k \in [K] \quad \text{f.}$$

דער אידן שטייט אין אים און אים אנטפערט:

$$\hat{\mu}_k^{MLE} = \bar{X}_k$$

$$\Rightarrow \text{for } \frac{\partial \ell}{\partial \mu_k} = -\frac{1}{\sigma_k^2} \sum_{i: y_i = k} (x_i - \mu_k) = 0$$

• (MLE) = maximum Likelihood estimators nec)

$$\frac{\partial l}{\partial \sigma_k^2} = -\frac{n_k}{2\sigma_k^2} - \frac{1}{2(\sigma_k^2)^2} \sum_{\{i|y_i=k\}} (x_i - \mu_k)^2 \quad : \text{ملاحظة}$$

$$(\hat{\sigma}^2)_K^{MLE} = \frac{1}{n_K} \sum_{\{i | y_i = k\}} (x_i - \hat{\mu}_K^{MLE})^2$$

$$\{\pi_i\} \approx \text{maximal} \quad \text{if } \pi_i \approx \pi_j$$

$$L = l(\theta | X, y) - \lambda \left(\sum_k \pi_k - 1 \right) \quad \text{כאשר}$$

אין משוואות:

$$\frac{\partial L}{\partial \pi_k} = \frac{\partial l(\theta | X, y)}{\partial \pi_k} - \lambda = \frac{n_k}{\pi_k} - \lambda = 0$$

$$\pi_k = \frac{n_k}{\lambda}$$

אין

$$\text{אין, משוואות} \quad \sum_k \pi_k = 1$$

$$\text{אין} \quad \lambda \text{ נמצא}$$

$$1 = \sum_k \pi_k = \sum_k \frac{n_k}{\lambda}$$

הנורמליזציה

$$\hat{\pi}_k^{MLE} = \frac{n_k}{m}$$

$$\text{אין} \quad \lambda = m$$

$$\text{אין} \quad \lambda = m$$

Likelihood funz

אין, אלו הם המאפיינים

אין

$$L(\theta | X, y) = \prod_{i=1}^m f_{X,Y}(x_i, y_i | \theta) = \prod_{i=1}^m f_{X|Y=y_i}(x_i) \cdot f_{Y|\theta}(y_i)$$

$$= \left(\prod_{j=1}^p \prod_{i=1}^m \mathcal{N}(x_{ij} | \mu_{y_i,j}, \sigma_{y_i,j}^2) \right) \cdot \text{mult}(y_i | \pi)$$

אין $l(\theta | X, y)$ - הפונקציה "log-likelihood" היא הפונקציה

$$l(\theta | X, y) = \sum_{i=1}^m \left(\log(\text{mult}(y_i | \pi)) + \sum_j \log(\mathcal{N}(x_{ij} | \mu_{y_i,j}, \sigma_{y_i,j}^2)) \right)$$

$$= \sum_k n_k \log(\pi_k) + \sum_k \sum_j \mathbb{1}_{[y_i=k]} \log(\mathcal{N}(x_{ij} | \mu_{kj}, \sigma_{kj}^2))$$

אין $j \in [d]$ - המאפיינים הם המאפיינים

אין j - המאפיינים הם המאפיינים

$$\hat{\pi}_k^{MLE} = \frac{n_k}{m}, \quad \hat{\mu}_{kj}^{MLE} = \frac{1}{n_{k \{i: y_i=j\}}} \sum_{i: y_i=j} x_{ij}, \quad (\hat{\sigma}^2)_{kj}^{MLE} = \frac{1}{n_k} \sum_{\{i: y_i=k\}} (x_{ij} - \hat{\mu}_{kj}^{MLE})^2$$

Likelihood func \leadsto נמצא (נציג את f) $\hat{=}$ ③

$$L(\theta | X, Y) = \prod_{i=1}^m f_{X,Y}(x_i, y_i | \theta) = \prod_{i=1}^m f_{X|Y=y_i}(x_i) \cdot f_{Y|\theta}(y_i) \\ = \prod_{i=1}^m \text{poi}(x_i | \lambda_{y_i}) \cdot \text{mult}(y_i | \pi)$$

\therefore log likelihood \leadsto נציג

$$l(\theta | X, Y) = \sum_{i=1}^m \log(\text{poi}(x_i | \lambda_{y_i})) + \log(\text{mult}(y_i | \pi)) \\ = \sum_{i=1}^m \log\left(\frac{\lambda_{y_i}^{x_i} e^{-\lambda_{y_i}}}{x_i!}\right) + \log(\pi_{y_i}) = \sum_{i=1}^m x_i \log(\lambda_{y_i}) - \lambda_{y_i} - \log(x_i!) + \log(\pi_{y_i}) \\ \uparrow \text{מציג} \\ \text{poi} \\ \text{על פניו}$$

$$= \sum_k (\log(\lambda_k) \sum_{i|y_i=k} x_i - n_k \cdot \lambda_k + n_k \log(\pi_k)) - \sum_{i=1}^m \log(x_i!)$$

\therefore מציג $\{\lambda_k\}$ \leadsto נציג את π_k

$$\frac{\partial l}{\partial \lambda_k} = \frac{1}{\lambda_k} \cdot \sum_{i|y_i=k} x_i - n_k = 0$$

$$\hat{\lambda}_k^{\text{MLE}} = \frac{1}{n_k} \sum \mathbb{1}_{[y_i=k]} x_i \quad \text{נציג}$$

\therefore מציג $\{\pi_k\}$ \leadsto נציג את π_k

$$\hat{\pi}_k^{\text{MLE}} = \frac{n_k}{m}$$

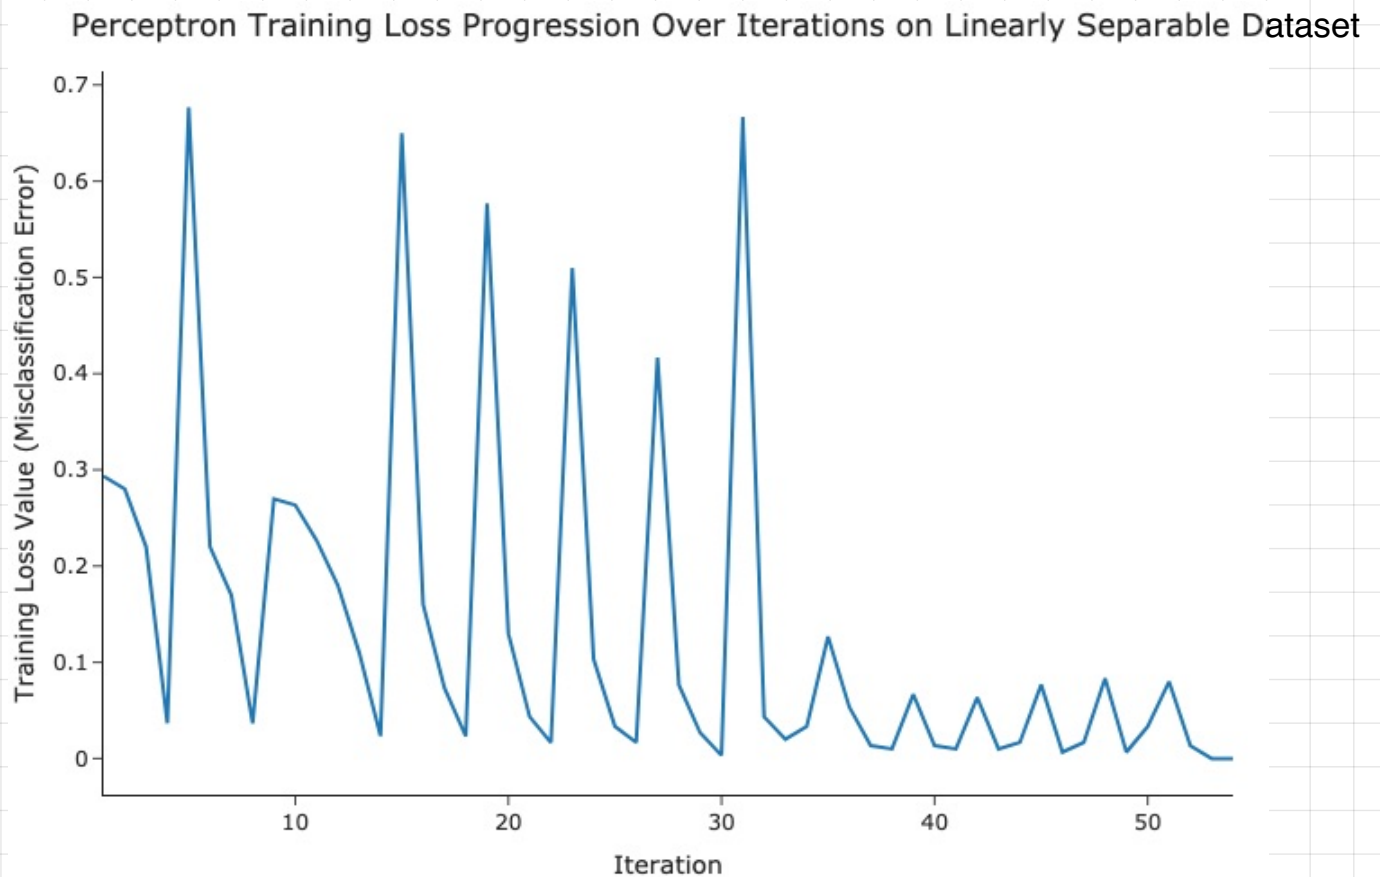
Likelihood func \leadsto נציג את f $\hat{=}$ ③

$$L(\theta | X, Y) = \prod_{i=1}^m f_{X,Y}(x_i, y_i | \theta) = \prod_{i=1}^m f_{X|Y=y_i}(x_i) f_{Y|\theta}(y_i) \\ = \prod_{i=1}^m \left(\prod_{j=1}^d \text{poi}(x_{ij} | \lambda_{y_i,j}) \right) \cdot \text{mult}(y_i | \pi)$$

$$l(\theta | X, Y) = \sum_{i=1}^m \sum_{j=1}^d (\log(\text{poi}(x_{ij} | \lambda_{y_i,j}))) + \sum_{i=1}^m \log(\text{mult}(y_i | \pi)) \\ = \sum_k \sum_j (\log(\lambda_{kj}) \sum_{i|y_i=k} x_{ij} - n_{kj} \cdot \lambda_{kj} + n_{kj} \log(\pi_{kj})) - \sum_{i,j} \log(x_{ij}!)$$


$$\hat{\lambda}_{kj}^{\text{MLE}} = \frac{1}{n_{kj}} \sum_i \mathbb{1}_{[y_i=k]} x_{ij}, \quad \hat{\pi}_{kj}^{\text{MLE}} = \frac{n_{kj}}{m} \quad \therefore \text{מציג} \quad \text{מציג}$$

3.1.1 מהגרף המוצג מטה אנו יכולים לראות את אופן פעולת האלגוריתם על dataset הניתן. ניתן לראות איך לאורך האיטרציות האלגוריתם 'מצליח' להוריד את misclassification error בעזרת ההתאמות ל coeffs שמבוצעות על ידי האלגוריתם. האלגוריתם אכן 'מצליח' לתקן את אופן החלוקה הלינארית שלו את הדגימות במרחב עד כדי הורדת error ל 0. מכך שהאלגוריתם הצליח לעשות דבר זה, גם אם הדבר כלל מספר איטרציות אשר גרמו לאלגוריתם להתקשות עם הורדת error, מעידה על כך שככל הנראה הדאטה הניתן לאלגוריתם במקרה זה היה ניתן להפרדה לינארית ברורה, עובדה האיפשרה לאלגוריתם למצוא חלוקה זו לבסוף.




3.1.2 בגרף המוצג מטה אנו רואים את פעילות האלגוריתם על הdataset השני. בנקל ניתן לשים לב כי האלגוריתם לא 'מצליח' להוריד את הmissclassification error על ידי חלוקה יעילה של הדאטה ותיקון מיקום קו החלוקה על ידי פעילות האלגוריתם על הcoeffs. ניתן לראות כי האלגוריתם הגיע למספר האיטרציות המקסימלי- 1000 בעוד שהerror אינו מראה מגמה של ירידה או קרבה ל0. ניתן להבין מכך על הדאטה הניתן כי ככל הנראה דאטה זה לא מאפשר חלוקה של כלל הsamples לשתי קבוצות ומעבר קו לינארי בדאטה, דבר המקשה על פעולת האלגוריתם ועל כך שבכל פעם שהוא 'מתקן' את הcoeffs הוא עדיין לא גורם להורדת הerror ועל כן הוא ממשיך לנסות על ידי תיקונים להוריד את הerror באיטרציות הבאות. דבר זה לא מתאפשר מכיוון שהדאטה הניתן ככל הנראה לא ניתן לחלוקה לינארית מבוקשת כזו.

Perceptron Training Loss Progression Over Iterations on Linearly Inseparable Dataset




3.2.1 בגרף המוצג מטה אנו יכולים לזהות שגם lda classifiern וגם gaussian naiven classifier מציגים את samples בצורה דומה ושרמת הדיוק שלהם כמעט זהה. על פי מה שלמדנו בתרגול ועל פי אופן הפעולה של שני classifiers אנו יכולים להבין כי ההתפלגות של הדגימות בדאטה סט זה היא גאוסיינית בעוד שרוב הדגימות הם בעלי covariance נמוך בין אחת לשנייה (וקרוב ל0), דבר אשר גרם לכך ששני המסווגים קיבלו תוצאות כמעט זהות.

Dataset: gaussian1.npy
Gaussian Naïve Bayes Accuracy: 0.95




LDA Accuracy: 0.94



3.2.2 בשונה מהגרף הקודם, פה אנו רואים כי הlda classifier השיג ביצועים גבוהים יותר מהgnc classifier. ניתן לראות זאת על ידי רמת הדיוק וההבדלים ביניהם (0.97 מול 0.85) וכן על פי האליפסות שנוצרו בשני המודלים וההתאמה שלהם אל הדגימות שבדאטה סט. מכיוון שהlda classifier 'מתחשב' במקרים בהם קיימת covariance (שונות) גבוהה בין הדגימות בדאטה סט בעוד שהgnc classifier לא, אנו יכולים להבין כי הדגימות בדאטה סט אכן כללו שונות גבוהה ביניהן ועל כן נוצר פער גדול בין המסוגים, כאשר מסווג הlda הצליח 'ללמוד' את השונות בין הדגימות ולקבל רמת דיוק גבוהה, בעוד שמסווג הגnc אשר מתבסס על הנחת שונות נמוכה עד אפסית בין הדגימות קיבל רמת דיוק נמוכה משמעותית.

Dataset: gaussian2.npy
Gaussian Naïve Bayes Accuracy: 0.85



LDA Accuracy: 0.97

